Rapport de Projet : Interface Intégrée de Data Mining

Nom : ALLALI **Prénom :** Mohamed Tadjedine

Classe : 4ème Software Engineering, G1

1. Introduction

Ce projet marque l'évolution d'une simple interface de clustering vers une solution de modélisation complète. L'objectif est de fournir un environnement unifié couvrant l'intégralité du cycle de vie des données : du chargement et nettoyage (Data Cleaning) à l'application de modèles d'apprentissage supervisé (**Classification**) et non-supervisé (**Clustering**).

2. Architecture Technique

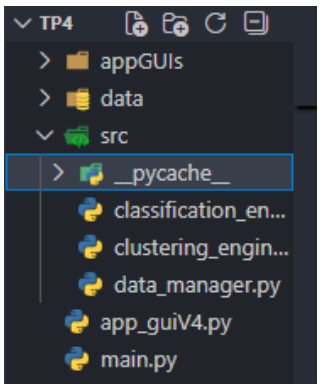
L'architecture a été étendue pour intégrer de nouveaux moteurs de calcul tout en conservant une modularité stricte (Pattern MVC).

2.1. Stack Technologique

- **Backend :** Python 3.x, Scikit-learn (Algorithmes), Pandas (DataFrames), SciPy (Dendrogrammes).
- **Frontend :** Tkinter avec thèmes ttk pour une navigation par onglets thématiques.
- **Visualisation :** Matplotlib et Seaborn intégrés via FigureCanvasTkAgg.

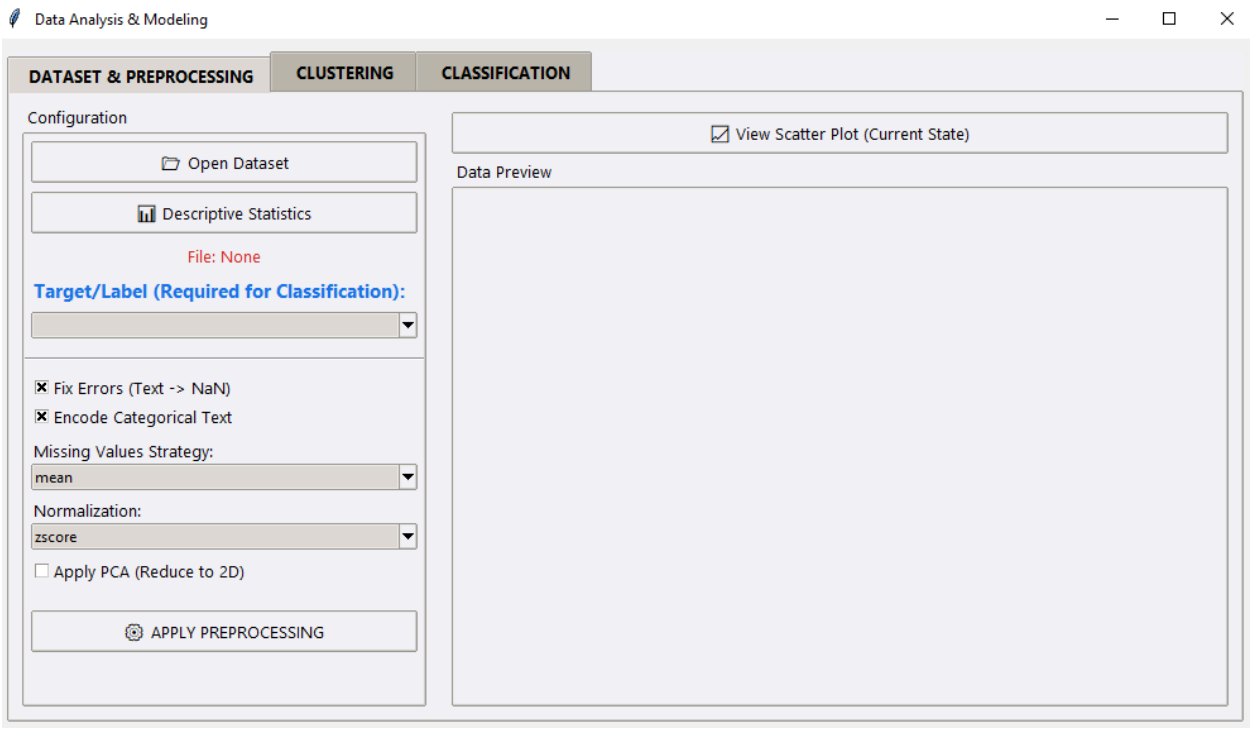
2.2. Structure du Code

1. **DataManager :** Gère le cycle de vie des données, incluant désormais le **Split Train/Test** et l'**Encodage des étiquettes**.
2. **ClusteringEngine :** Responsable des algorithmes non-supervisés (5 méthodes).
3. **ClassificationEngine :** Module dédié à l'entraînement des modèles supervisés



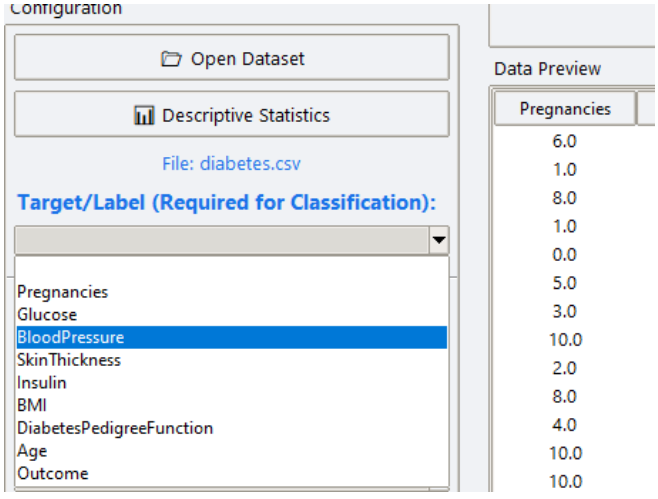
3. Prétraitement et Exploration

L'onglet "Dataset" a été repensé pour servir de base de contrôle à toutes les analyses ultérieures.

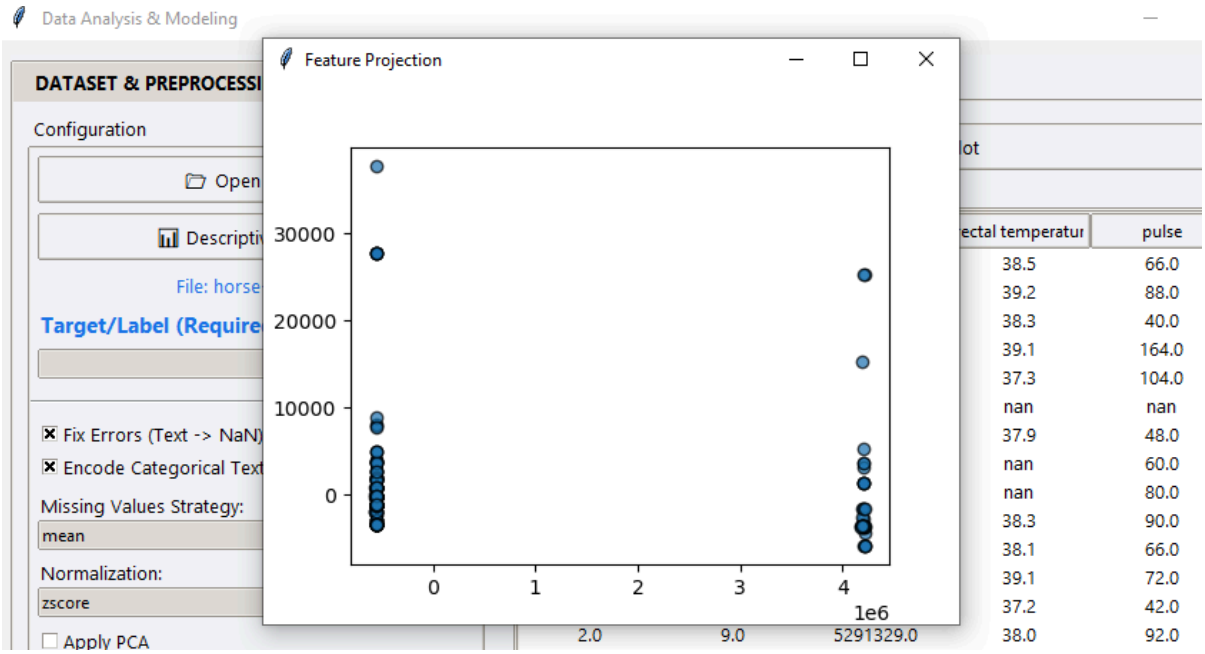


Configuration :

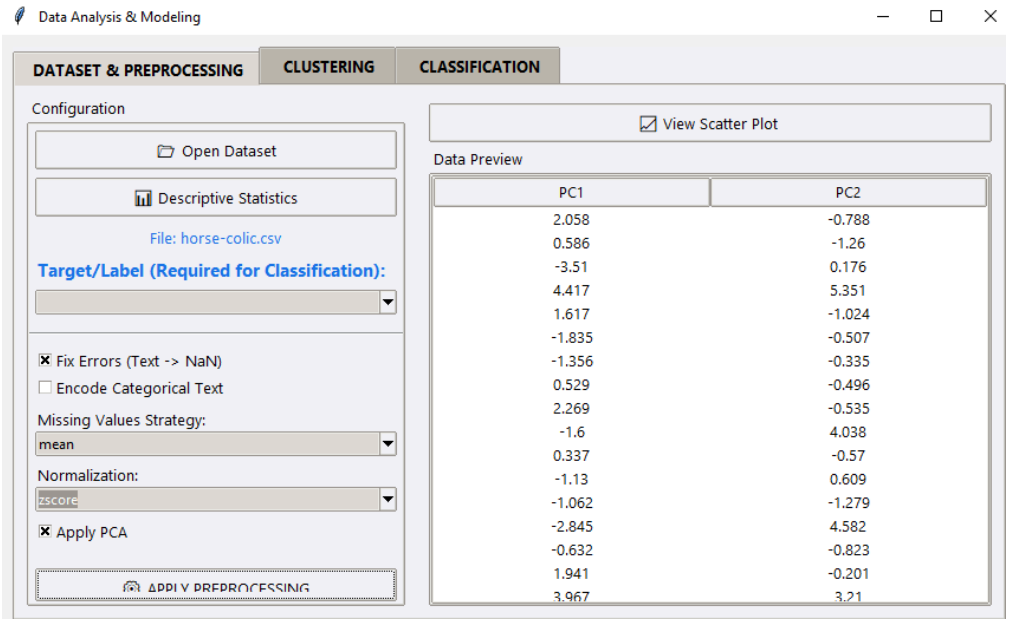
- **Gestion de la Cible (Target) :** Ajout d'une sélection dynamique de la colonne cible. Le système valide désormais la présence d'une cible avant d'autoriser la classification, avec affichage d'une erreur explicite en cas d'oubli.

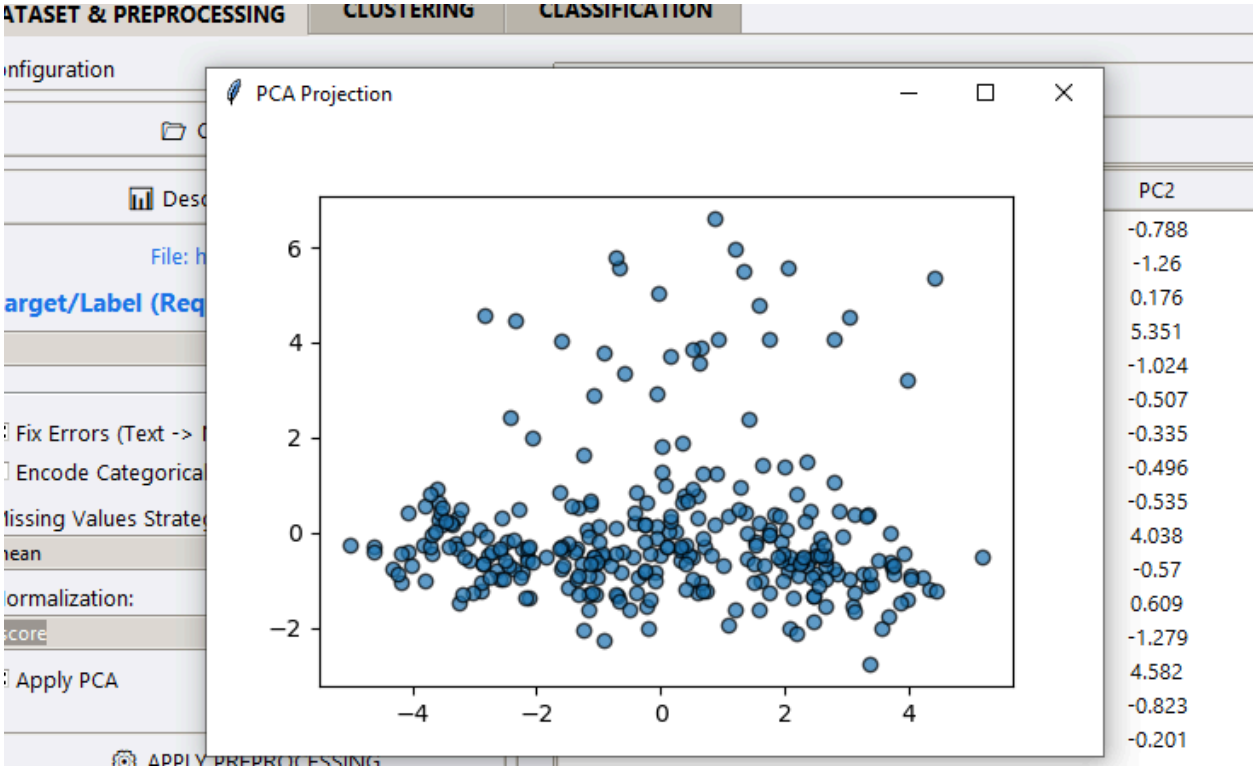


- **PCA Dynamique :** le PCA est optionnel. L'utilisateur choisit d'activer ou non la réduction de dimension à 2 composantes principales.
- **Visualisation Contextuelle :** Le bouton "Scatter plot" adapte son affichage selon l'état des données : il affiche les composantes PC1/PC2 si le PCA est actif, ou une projection 2D des caractéristiques brutes sinon.



Après l'application du prétraitement (avec PCA) :





4. Analyse par Clustering

Le module de clustering a été affiné pour une ergonomie accrue et une meilleure interprétation scientifique.

Fonctionnalités majeures :

- **Interface Adaptative pour DBSCAN :** Lors du choix de l'algorithme DBSCAN, le paramètre "K" est masqué dynamiquement pour laisser place aux entrées spécifiques **Epsilon** et **Min Samples**.
- **Visualisation des Centroïdes :** Pour **KMeans** et **KMedoids**, les centres de clusters sont désormais marqués par des **croix rouges (X)** sur le graphique de projection.

Data Analysis & Modeling

DATASET & PREPROCESSING | CLUSTERING | CLASSIFICATION

Parameters

Algorithm:

KMeans

Number of Clusters (K):

3

Run Clustering

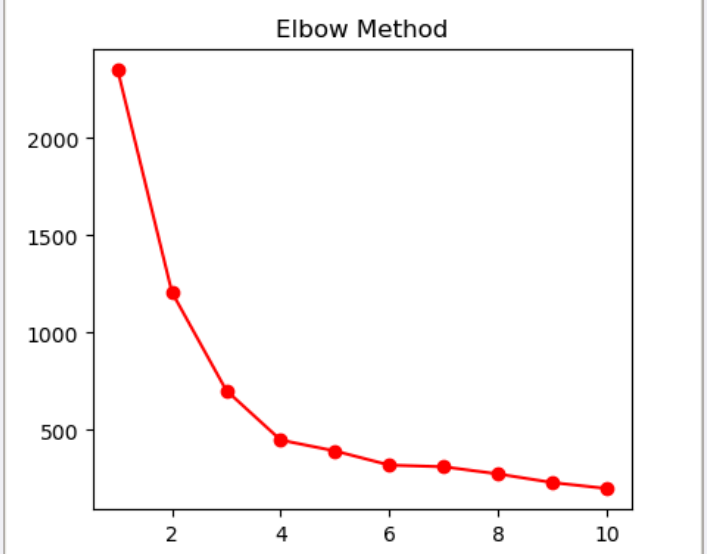
Elbow Method

Dendrogram

Algorithm Comparison

Metrics: -

Cluster Projection



Parameters

Algorithm:

KMeans

Number of Clusters (K):

3

Run Clustering

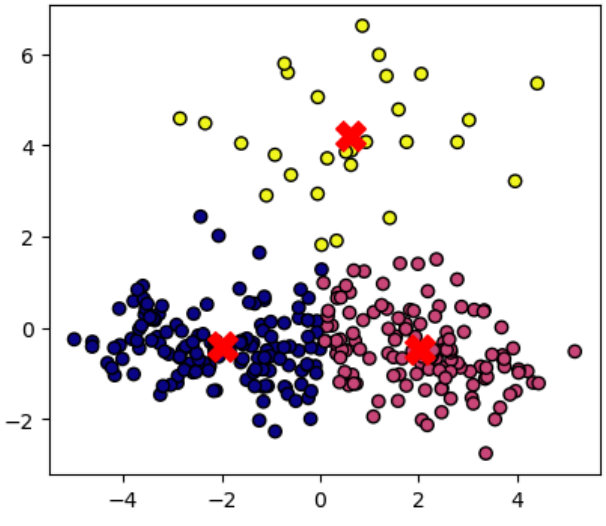
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.513
Inertia: 702.17

Cluster Projection



DATASET & PREPROCESSING | CLUSTERING | CLASSIFICATION

Parameters

Algorithm:

KMedoids

Number of Clusters (K):

3

Run Clustering

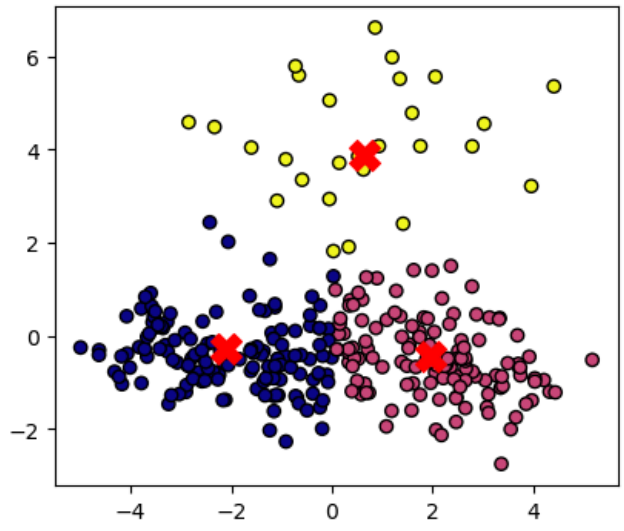
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.513
Inertia: 702.17

Cluster Projection



Parameters

Algorithm:

AGNES

Number of Clusters (K):

3

Run Clustering

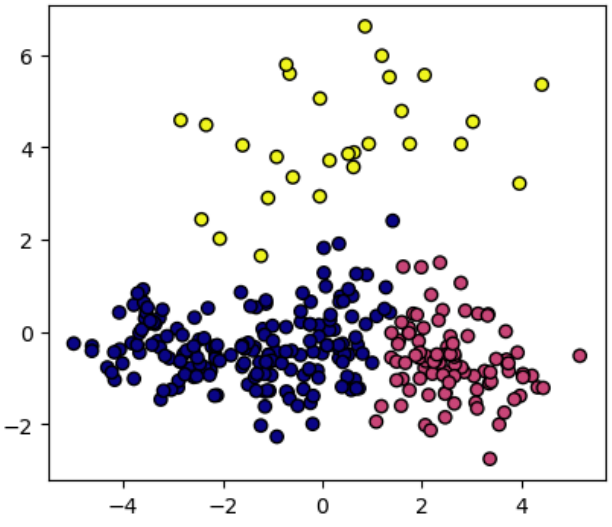
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.485
Inertia: 806.56

Cluster Projection



DATASET & PREPROCESSING | CLUSTERING | CLASSIFICATION

Parameters

Algorithm:

DBSCAN

Epsilon (eps):

0.7

Min Samples:

5

Run Clustering

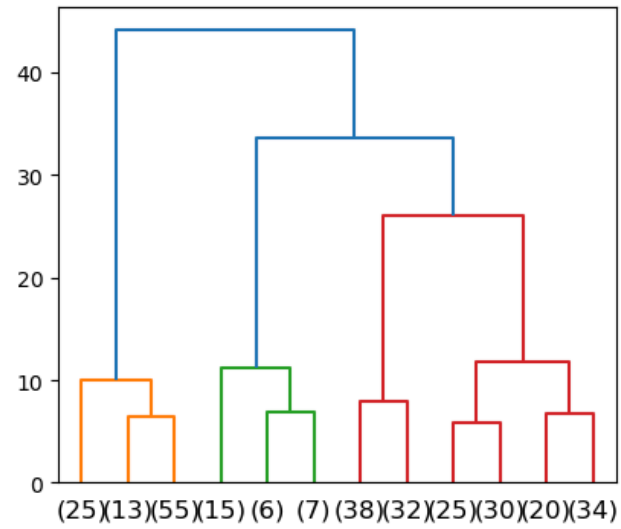
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.321

Cluster Projection



Parameters

Algorithm:

DIANA

Number of Clusters (K):

3

Run Clustering

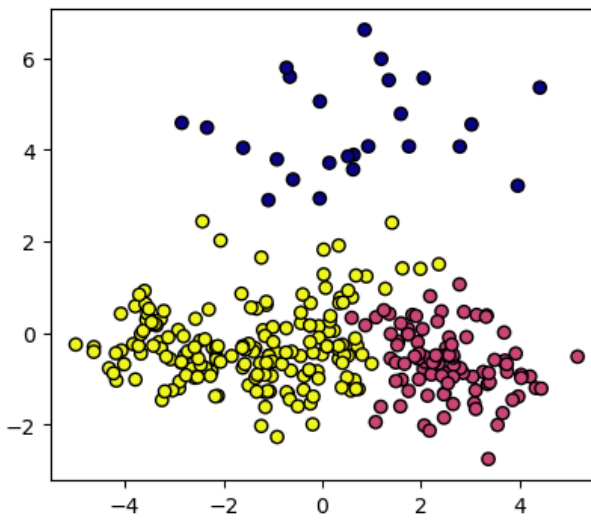
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.485
Inertia: 805.59

Cluster Projection



Parameters

Algorithm:

DBSCAN

Epsilon (eps):

0.7

Min Samples:

5

Run Clustering

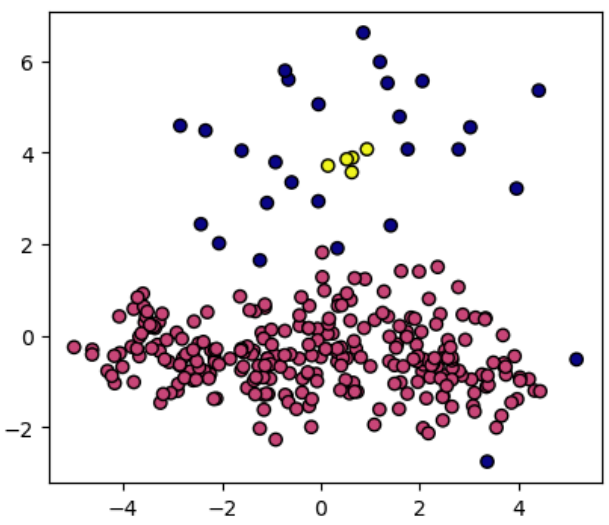
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.321

Cluster Projection



DATASET & PREPROCESSING | CLUSTERING | CLASSIFICATION

Parameters

Algorithm:

DBSCAN

Epsilon (eps):

0.7

Min Samples:

5

Run Clustering

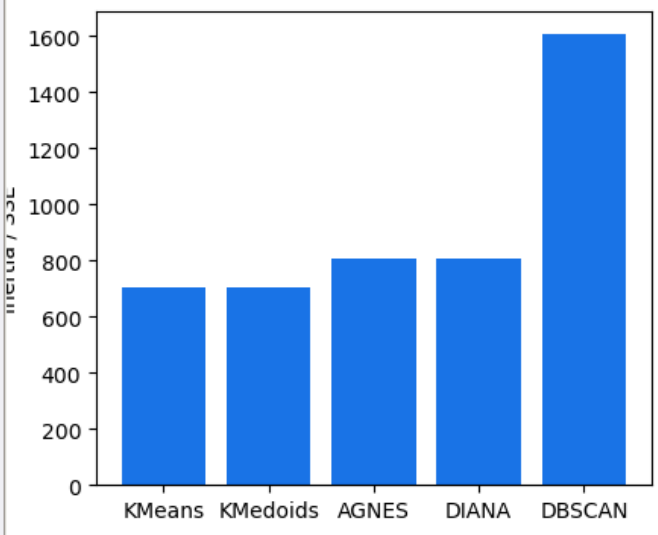
Elbow Method

Dendrogram

Algorithm Comparison

Silhouette: 0.321

Cluster Projection

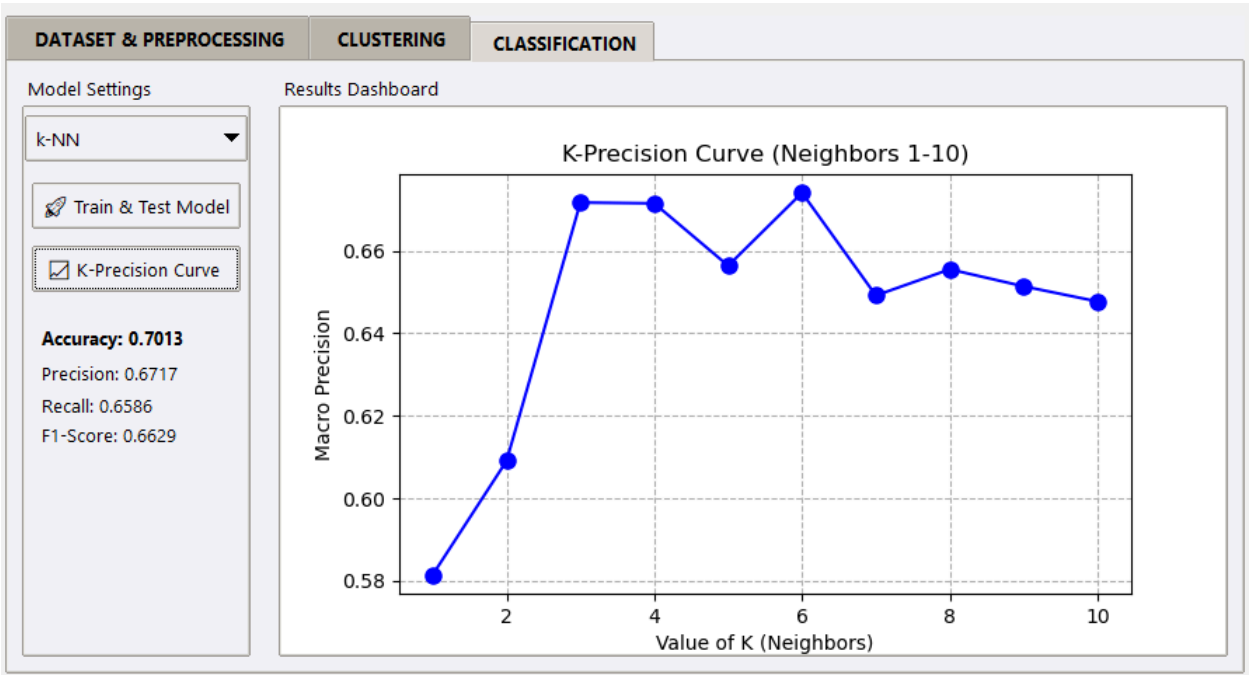


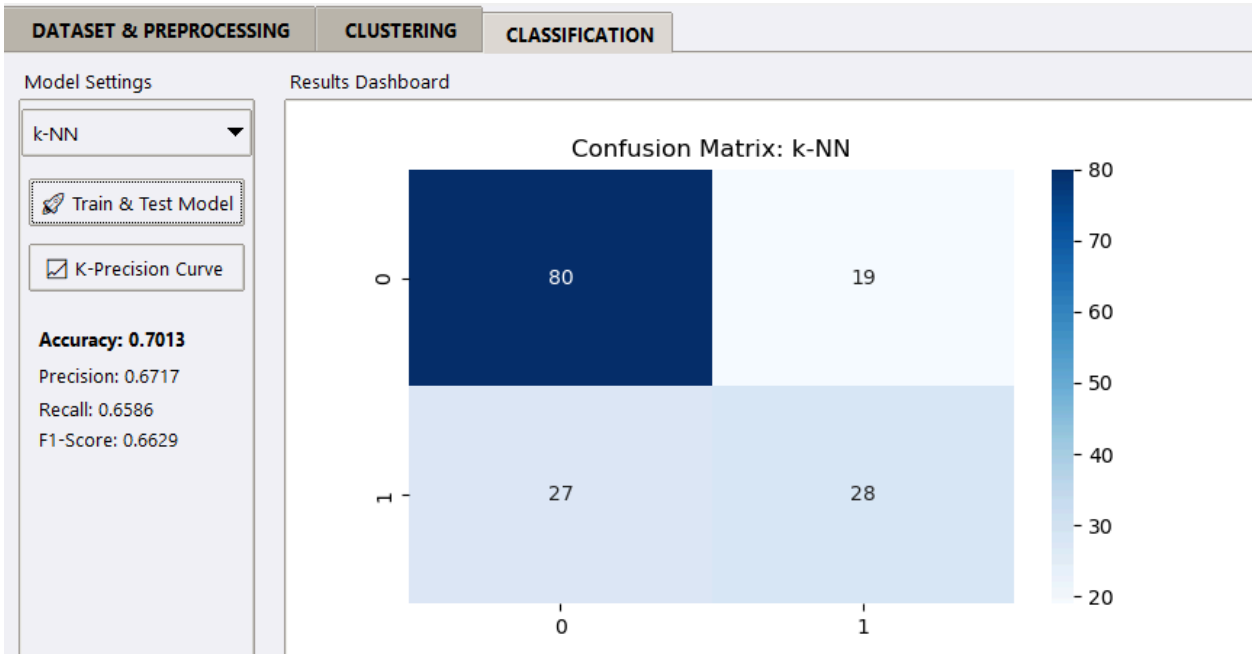
5. Analyse par Classification

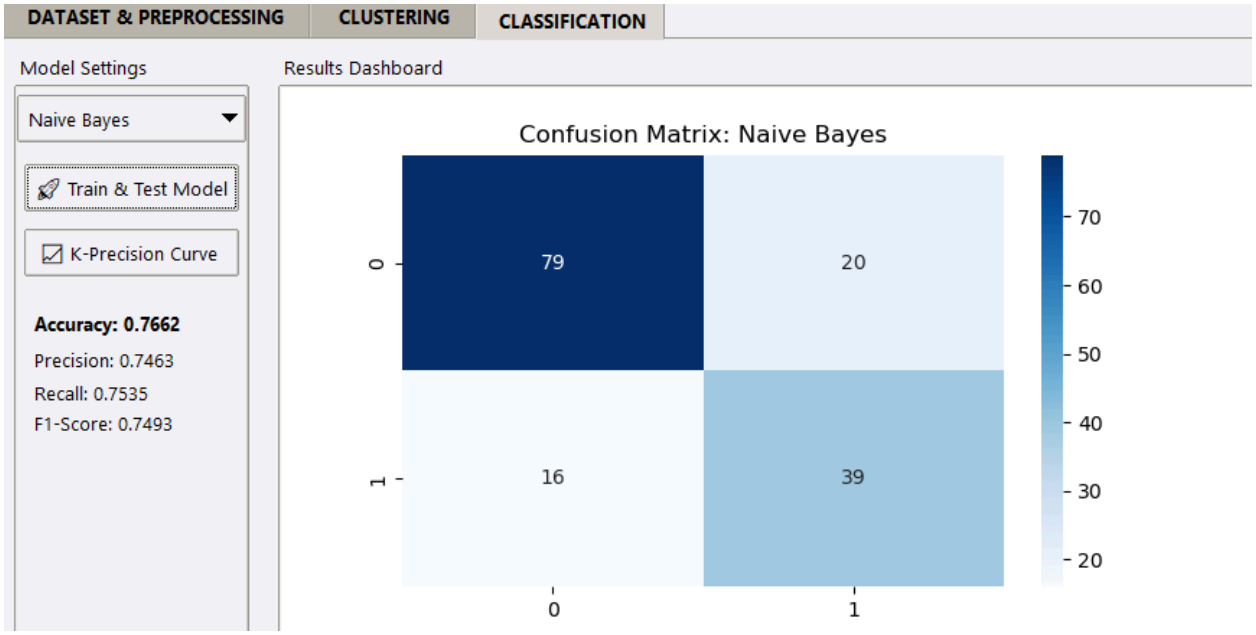
Une fonctionnalité majeure ajoutée à ce projet.

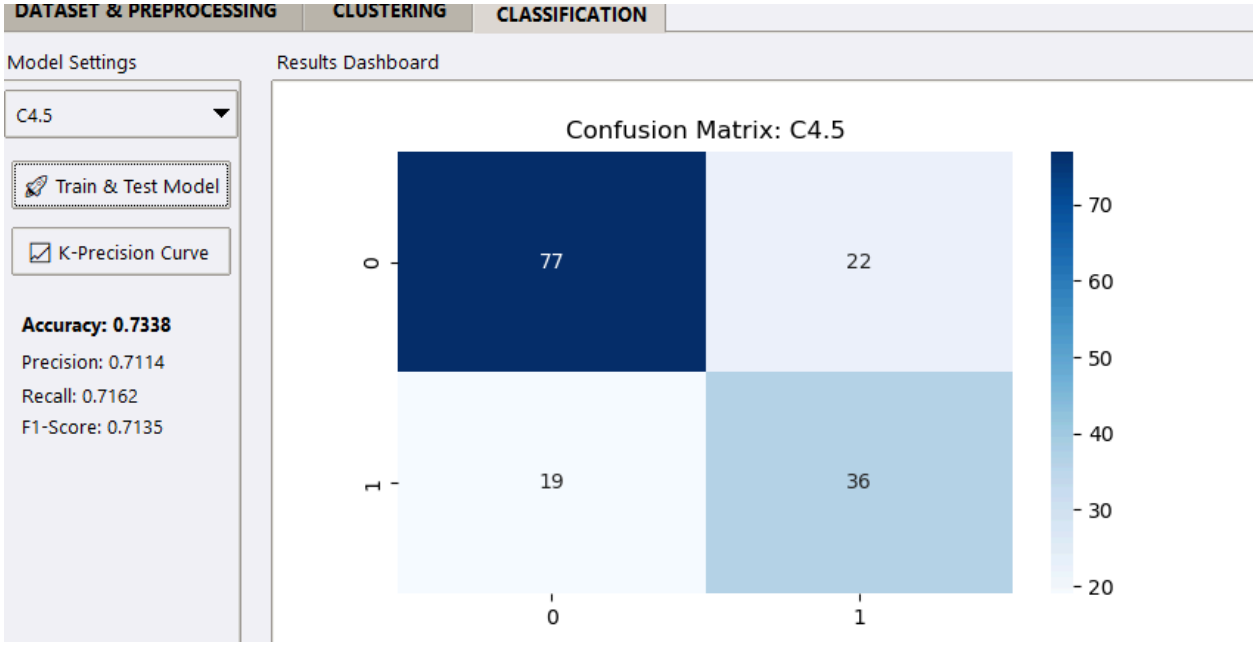
Caractéristiques :

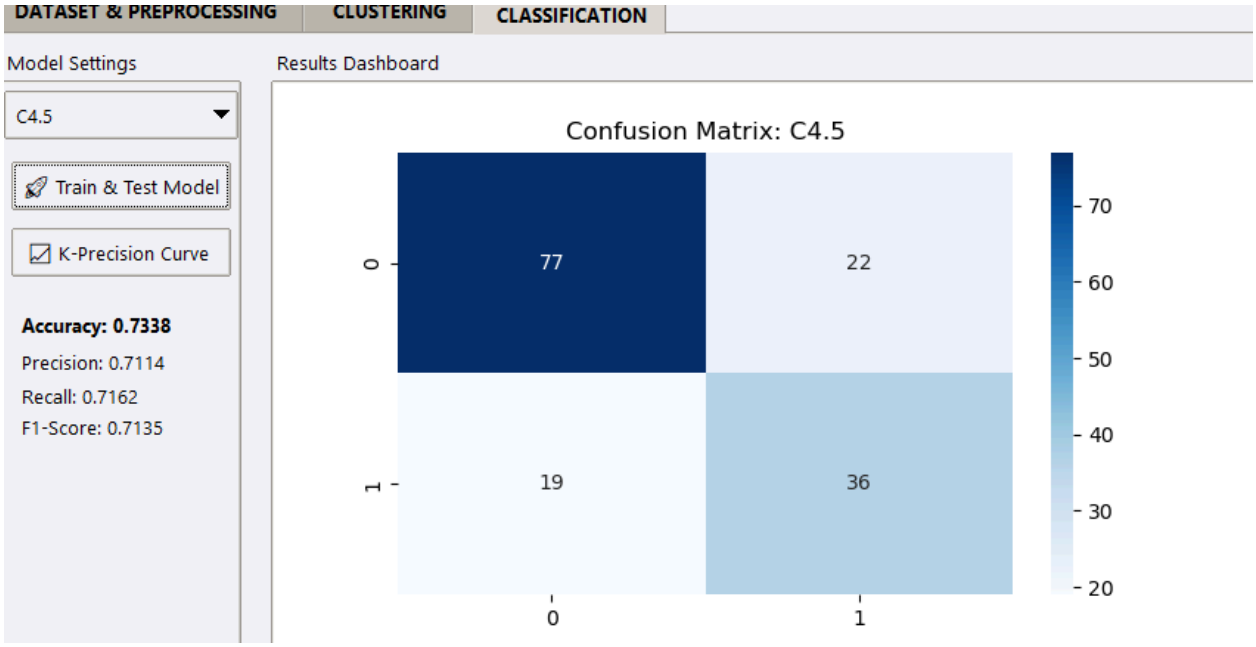
- **Algorithmes supportés :** k-NN, Naive Bayes, C4.5 (Arbre de décision) et SVM.
- **Tableau de Bord des Métriques :** Affichage automatique de l'**Accuracy**, **Precision**, **Recall** et **F1-Score**.
- **Matrice de Confusion :** Visualisation par Heatmap Seaborn pour identifier les classes confondues par le modèle.
- **Courbe d'Optimisation K-Precision :** Un outil dédié au k-NN permettant de visualiser l'évolution de la précision en fonction du nombre de voisins (K variant de 1 à 10).




DATASET & PREPROCESSING
CLUSTERING
CLASSIFICATION
Model Settings
Results Dashboard
k-NN
Train & Test Model
K-Precision Curve
Accuracy: 0.7013
Precision: 0.6717
Recall: 0.6586
F1-Score: 0.6629
Confusion Matrix: k-NN
80
19
27
28
0
1
0
1
80
70
60
50
40
30
20


DATASET & PREPROCESSING
CLUSTERING
CLASSIFICATION
Model Settings
Results Dashboard
Naive Bayes
Train & Test Model
K-Precision Curve
Accuracy: 0.7662
Precision: 0.7463
Recall: 0.7535
F1-Score: 0.7493
Confusion Matrix: Naive Bayes
79
20
16
39
0
1
0
1
70
60
50
40
30
20


DATASET & PREPROCESSING
CLUSTERING
CLASSIFICATION
Model Settings
Results Dashboard
C4.5
Train & Test Model
K-Precision Curve
Accuracy: 0.7338
Precision: 0.7114
Recall: 0.7162
F1-Score: 0.7135
Confusion Matrix: C4.5
77
22
19
36
0
1
0
1
70
60
50
40
30
20


DATASET & PREPROCESSING
CLUSTERING
CLASSIFICATION
Model Settings
Results Dashboard
C4.5
Train & Test Model
K-Precision Curve
Accuracy: 0.7338
Precision: 0.7114
Recall: 0.7162
F1-Score: 0.7135
Confusion Matrix: C4.5
77
22
19
36
0
1
0
1
70
60
50
40
30
20

6. Gestion des Erreurs et Expérience Utilisateur (UX)

L'application est devenue plus robuste :

- **Pop-ups d'alerte :** Des messages d'erreur guident l'utilisateur (ex: oubli de chargement de fichier ou de définition de cible).

7. Conclusion

Cette interface transforme l'expérience de data mining en un processus fluide et interactif. En combinant la classification et le clustering dans un seul environnement graphique, l'outil permet une compréhension approfondie et immédiate du comportement des données et de l'efficacité des modèles choisis.